

proyecto01

April 6, 2022

1 Proyecto 1 - Series de Tiempo I

1.0.1 Bruno Martinez - Cristóbal Cancino

1.0.2 Prof. Ronny Vallejos

1.1 ### 06 de abril de 2022

```
[1]: library("zoo")
library("tseries")
library("tidyverse")
library("fpp2")
```

Attaching package: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

Registered S3 method overwritten by 'xts':

method from
as.zoo.xts zoo

Registered S3 method overwritten by 'quantmod':

method from
as.zoo.data.frame zoo

Attaching packages

tidyverse 1.3.1

ggplot2	3.3.5	purrr	0.3.4
tibble	3.1.6	dplyr	1.0.8
tidyr	1.2.0	stringr	1.4.0
readr	2.1.2	forcats	0.5.1

Conflicts

```
tidyverse_conflicts()
dplyr::filter() masks stats::filter()
dplyr::lag()     masks stats::lag()
```

Attaching packages

fpp2 2.4

```
forecast 8.16      expsmooth 2.3
fma       2.4
```

2 Problema 1


Considere la serie `flu.dat` que puede ser obtenida en el sitio <http://www.stat.pitt.edu/stoffer/tsa2/tsa2.html>.

1. Transforme la serie adecuadamente para observar el efecto de la transformación en la media y la varianza

Se graficarán los datos

```
[2]: flu <- ts(read.table("https://www.stat.pitt.edu/stoffer/tsa2/data/flu.dat.
↪txt"), frequency=12)
length(flu)
ts.plot(flu, main = 'Flu')
```

132




Deseamos estabilizar la varianza, en particular, reducir la dependencia de la variabilidad del tiempo. Para esto, se utilizará la **Media movil**.

```
[3]: rm_flu <- rollmean(flu, 5)
      head(rm_flu)
```

A Time Series: 1 × 6

	Mar	Apr	May	Jun	Jul	Aug
1	0.4249440	0.3131781	0.2733503	0.2540707	0.2441794	0.2466861

```
[4]: seqplot.ts(flu,rm_flu)
```



```
[5]: mean(rm_flu)
     mean(flu)
```

```
0.28863929609375
```

```
0.291862284090909
```

```
[6]: var(rm_flu)[1,1]
     var(flu)[1,1]
```

```
0.00615542112341169
```

```
0.0157817324621534
```

Podemos ver que se cumple el **Resultado 1.6**, es decir, la media se mantiene relativamente con-

stante y la varianza cambia pues se transforma en $\frac{\sigma^2}{2*q+1}$, donde se usó $q = 5$.

2. Se propone un modelo de la forma

$$Z_t = \sum_{j=0}^{\infty} \beta_j t^j + \epsilon_t$$

donde ϵ_t es un ruido blanco con varianza σ^2 .

1. Proponga un método que permita truncar la serie infinita que define el modelo, de tal modo que el modelo resultante sea de la forma

$$Z_t = \sum_{j=0}^p b_j t^j + u_t,$$

donde $p \in \mathbb{N}$. Es decir, proponga un método para estimar p .

2. Estime p usando los datos de la serie `flu.dat`.
3. Estime los parámetros del modelo: β_j , $j = 0, 1, \dots, \hat{p}$, donde \hat{p} es la estimación de p propuesta en B. **Solución.**

Se propone transformar el modelo de la forma

$$Z_t = \sum_{j=0}^{\infty} \beta_j t^j + \epsilon_t \quad \Rightarrow \quad Z_t = \sum_{j=0}^p \beta_j t^j + \underbrace{\sum_{j=p+1}^{\infty} \beta_j t^j}_{u_t} + \epsilon_t$$

donde $u_t \approx N(\sum_{j=p+1}^{\infty} \beta_j t^j, \sigma^2)$. Para estimar p , se propone el siguiente método basado en el filtrado de Diferenciación y la Proposición 1.1.

```
FUNCTION obtener_p(datos)
p = 0
for(){
    datos <- diff(datos)
    calcular regresion lineal
    si |pendiente| < tol
        break
    p += 1
}
return p
```

En particular, utilizando los datos

```
[7]: diff_datos <- rm_flu
p <- 0
tol <- 10^-5
previous_slope <- Inf
while(TRUE){
    diff_datos <- diff(diff_datos)
    range <- ts(1:length(diff_datos))
    regression <- lm(diff_datos ~ range)
    slope <- abs(regression$coefficients["range"])
    if(slope < tol | slope > previous_slope){
```

```

        break
      }
      previous_slope <- slope
      p <- p + 1
    }
  }
  p

```

1

De esta forma, se tiene un modelo de regresión lineal, por lo que se calculará utilizando `lm`.

```

[8]: q <- ts(1:length(flu), frequency=12)
      regression <- lm(flu ~ poly(q,p,raw=TRUE))
      regression

```

Call:

```
lm(formula = flu ~ poly(q, p, raw = TRUE))
```

Coefficients:

```

      (Intercept)  poly(q, p, raw = TRUE)
      0.3527291      -0.0009153

```

3. Grafique la serie original y la serie ajustada en un mismo gráfico. Hay evidencia para aseverar que el modelo estimado es una buena representación de los patrones de la serie original? Justifique.


```

[9]: intercept = regression$coefficients["(Intercept)"]
      range <- 1:length(flu)
      regressiondata <- matrix(1, length(flu), 1)*intercept

      if(p == 1){
        regressiondata <- regressiondata + 1:
        ↪length(flu)*regression$coefficients["poly(q, p, raw = TRUE)"]
      } else {
        for(i in 1:p){
          regressiondata <- regressiondata + 1:
          ↪length(flu)*regression$coefficients[paste("poly(q, p, raw = TRUE)",i, sep = "_
          ↪")]
        }
      }

      regressionts = ts(regressiondata, frequency=12)
      seqplot.ts(flu, regressionts)

```



4. Ajuste un modelo de descomposición a la serie `flu.dat`.

```
[10]: flu <- ts(read.table("https://www.stat.pitt.edu/stoffer/tsa2/data/flu.dat.
  ↪txt"), frequency=12)
```

Se estimará la tendencia a través de un modelo lineal.

```
[11]: ma_flu <- ts(rollmean(flu, 5), frequency=12)
range <- ts(1:length(ma_flu), frequency=12)
regression <- lm(ma_flu ~ range)
regression
```


Call:

```
lm(formula = ma_flu ~ range)
```

Coefficients:

```
(Intercept)      range  
  0.3379070  -0.0007638
```


```
[12]: intercept = regression$coefficients["(Intercept)"]  
slope = regression$coefficients["range"]  
range <- ts(1:length(ma_flu), frequency=12)  
trend <- ts(intercept + slope * range, frequency=12)  
seqplot.ts(ma_flu, trend, ylab="Flu")
```



Estimamos entonces el modelo estacional


```
[13]: seasonal <- ma_flu - trend
```

```
[14]: linearmodel <- ts(trend + seasonal, frequency=12)  
seqplot.ts(flu,linearmodel)
```




5. Ajuste un modelo de Holt-Winters a la serie `flu.dat`.

```
[15]: flu <- ts(flu, frequency=12)  
hw_flu <- HoltWinters(flu)  
plot(hw_flu)  
summary(hw_flu)
```

	Length	Class	Mode
fitted	480	mts	numeric

x	132	ts	numeric
alpha	1	-none-	numeric
beta	1	-none-	numeric
gamma	1	-none-	numeric
coefficients	14	-none-	numeric
seasonal	1	-none-	character
SSE	1	-none-	numeric
call	2	-none-	call

Holt-Winters filtering



6. De los modelos propuestos en la parte 2., 4. y 5., ¿cuál es el más apropiado?

El modelo 5. parece ser más apropiado.

3 Problema 2


En este ejercicio es necesario obtener la serie asociada al calentamiento de la tierra descrito en grados centígrados entre los años 1900-1997. Esta serie es presentada en Shumway and Stoffer (2000), página 5. Para bajar el archivo `globtemp.dat`, encuentre el sitio web <http://www.stat.pitt.edu/stoffer/tsa2/tsa2.html>.

1. Grafique la serie `globtemp.dat` en el tiempo.

```
[16]: globtemp <- ts(read.table("https://www.stat.pitt.edu/stoffer/tsa2/data/globtemp.
    ↪dat.txt"))
head(globtemp)
```

	V1
	-0.36
	-0.48
A Time Series: 6 × 1	-0.43
	-0.25
	-0.39
	-0.43

```
[17]: ts.plot(globtemp, main='Global Temperature in Time', ylab="Global Temperature")
```



2. Use un modelo de suavizamiento exponencial simple para predecir la serie hacia el futuro. Considere un valor apropiado para α .


Debemos recordar que para utilizar un modelo de suavizamiento exponencial simple, se deben quitar los datos de prueba.

```
[18]: length(globtemp)
```

```
142
```


```
[19]: globtemp.train <- window(globtemp, end = 100)
      globtemp.test <- window(globtemp, start = 101)
```

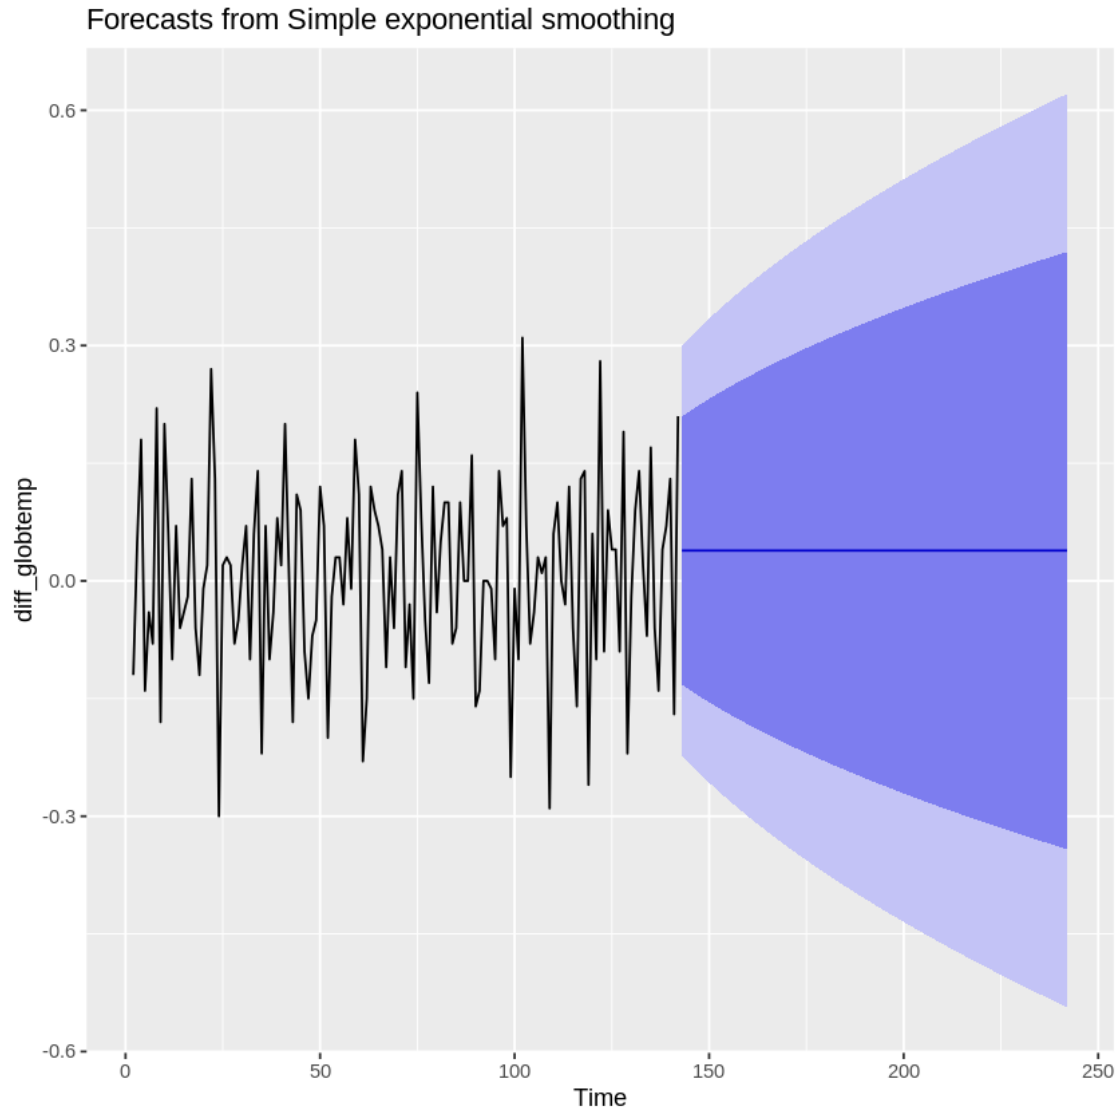
```
[20]: ses_globtemp <- ses(globtemp, alpha = .2, h = 100)
      autoplot(ses_globtemp)
```



Observamos que no está capturando la tendencia correctamente. Esto es porque el Suavizamiento

```
[21]: diff_globtemp <- diff(globtemp)
      plot(diff_globtemp)
      ses_diff_globtemp <- ses(diff_globtemp, alpha = .2, h = 100)
      autoplot(ses_diff_globtemp)
```






3. Describa las bondades y limitaciones del modelo usado en los puntos anteriores.

Entre las bondades que uno puede encontrar, se tiene que le da mayor peso al pasado reciente y

El mayor problema del modelo es que no son precisos al momento de utilizar tendencias, y es por

4. A partir de la serie original obtenga una serie sin tendencia.

```
[22]: diff_globtemp = diff(globtemp)
      plot(diff_globtemp)
```



5. Estime un modelo de regresión de la forma

$$Z_t = \beta_0 + \beta_1 t + \epsilon_t,$$


para la serie `globtemp.dat`, donde ϵ_t es una colección de variables aleatorias no correlacionadas en media cero y varianza δ^2 . ¿El modelo ajustado luce similar a la serie original?

```
[23]: range <- ts(1:length(globtemp))
      regression <- lm(globtemp ~ range)

      intercept = regression$coefficients["(Intercept)"]
      slope = regression$coefficients["range"]
      trend <- intercept + slope * range
```




```
seqplot.ts(globtemp, trend, ylab="Global Temperature")
```



6. Descomponga la serie `globtemp.dat` en tres partes: una tendencia, una parte estacional y una componente residual. Describa que observa.

```
[24]: dec_globtemp <- ts(globtemp, frequency=12)
      dec <- decompose(dec_globtemp)
      plot(dec)
```



Podemos observar que los datos poseen una componente estacional notable, asi como la tendencia

4 Problema 3

Al analizar cierta serie de tiempo trimestral se usó un método ingenuo obteniéndose:

1. Ecuación de tendencia $T(t) = 84.65 + 4.71t$.

2. Serie de residuos $W(t) = Y(t) - Z(t)$.

Trimestre	1997	1998	1999	2000	2001				
1	-6.25	-7.50	-7.50	2.50					
2	-11.25	-11.25	-21.50	-13.75	-				
3	0.95	1.05	1.11	1.05	-				

En base a los resultados de 1. y 2., dado que $t = 1$ corresponde al primer trimestre de 1997, prediga los valores de la serie en cada uno de los trimestres de 2002.

Solución.

Primero obtendremos los valores de los e_i , con $i = 1, \dots, 4$. Note que e_i corresponde al promedio de los $W(t)$ de cada trimestre. Calculando:

- $e_1 = (20 + 15 + 13.75 + 8.75)/4 = 14.38$
- $e_2 = (-6.25 - 7.50 - 7.50 + 2.50)/4 = -4.69$
- $e_3 = (-11.25 - 11.25 - 21.50 - 13.75)/4 = -14.44$
- $e_4 = (0.95 + 1.05 + 1.11 + 1.05)/4 = 1.04$

Calculando el promedio de los e_i , para $i = 1, \dots, 4$

$$\bar{e} = (14.38 - 4.69 - 14.44 + 1.04)/4 = -0.93$$

Por otra parte la estimacion de la componente estacional, está dada por:

- $\hat{E}_1 = e_1 - \bar{e} = 15.31$
- $\hat{E}_2 = e_2 - \bar{e} = -3.76$
- $\hat{E}_3 = e_3 - \bar{e} = -13.51$
- $\hat{E}_4 = e_4 - \bar{e} = 1.97$

Note que la tendencia viene dada por $T_t = 84.65 + 4.71 * t$, y dado que nos piden predecir los valores de Z para el año 2002, entonces tendremos que calcular los trimestres 21,22,23,24. En efecto:

- $\hat{T}_{21} = 183.56$
- $\hat{T}_{22} = 188.27$
- $\hat{T}_{23} = 192.98$
- $\hat{T}_{24} = 197.69$

Finalmente , calculando lo pedido (los valores de la serie para cada trimestre del año 2002).

- $\hat{Z}_{21} = \hat{T}_{21} + \hat{E}_1 = 198.87$
- $\hat{Z}_{22} = \hat{T}_{22} + \hat{E}_2 = 184.51$
- $\hat{Z}_{23} = \hat{T}_{23} + \hat{E}_3 = 179.47$
- $\hat{Z}_{24} = \hat{T}_{24} + \hat{E}_4 = 199.66$

5 Problema 4

Considere una serie de tiempo $\{Z_t : t \in T\}$ descrita por la ecuación:

$$Z_t = \beta_0 + \beta_1 t + \beta_2 t^2 + S_t + \epsilon_t$$

donde β_0 , β_1 y β_2 son parámetros desconocidos del modelo, S_t es un efecto estacional conocido y ϵ_t es un ruido aleatorio con media y varianza constante. Determine las ecuaciones que permiten estimar los parámetros β_0 , β_1 y β_2 .

Solución.

Considere una serie de tiempo $Z_t : t \in T$ descrita por la ecuacion:

$$Z_t = \beta_0 + \beta_1 * t + \beta_2 * t^2 + S_t + \epsilon_t.$$

Note que la serie puede ser escrita de la siguiente forma:

$$Z_t = T_t + S_t + \epsilon_t,$$

con T_t , un modelo cuadratico de la estimacion de la tendencia. Por otra parte, notemos que S_t corresponde a la componente estacional y en este caso la eliminaremos debido a que se considera poco interesante y dificulta nuestro analisis. Por lo que obtenemos la siguiente serie:

$$Z_t = \beta_0 + \beta_1 * t + \beta_2 * t^2 + \epsilon_t, t \in T$$

la cual puede ser resuelta a traves de una regresion polinomial.

Por tanto el modelo se puede escribir como un sistema de ecuaciones lineales

$$\begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ \vdots \\ \vdots \\ z_T \end{bmatrix} = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots \\ 1 & t_T & t_T^2 \end{bmatrix} \cdot \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \\ \vdots \\ \vdots \\ \epsilon_T \end{bmatrix}$$

y por ende de forma matricial nos quedaria de la forma:

$$Z = X\beta + \epsilon$$

Ahora podemos obtener el vector de coeficientes de regresion polinomial estimados , usando la estimacion de minimos cuadrados. Obteniendo asi:

$$\hat{\beta} = (X^T * X)^{-1} * X^T * Z$$

la unica solucion a traves de minimos cuadrados, si

$$(X^T * X)$$

es invertible. Por tanto lo unico que nos queda verificar es lo ,mencionado anteriormente. En efecto:

$$(X^T * X) = \begin{bmatrix} 1 & 1 & 1 & \vdots & \vdots & \vdots & 1 \\ t_1 & t_2 & t_3 & \vdots & \vdots & \vdots & t_T \\ t_1^2 & t_2^2 & t_3^2 & \vdots & \vdots & \vdots & t_T^2 \end{bmatrix} = \begin{bmatrix} 1 & t_1 & t_1^2 \\ 1 & t_2 & t_2^2 \\ \vdots & \vdots & \vdots \\ \vdots & \vdots & \vdots \\ 1 & t_T & t_T^2 \end{bmatrix} = \begin{bmatrix} T & \sum_{i=1}^T t_i & \sum_{i=1}^T t_i^2 \\ \sum_{i=1}^T t_i & \sum_{i=1}^T t_i^2 & \sum_{i=1}^T t_i^3 \\ \sum_{i=1}^T t_i^2 & \sum_{i=1}^T t_i^3 & \sum_{i=1}^T t_i^4 \end{bmatrix}$$

.

Como $t_i \geq 0$, y los $t_{i+1} > t_i$, entonces se puede verificar claramente que el $\det(X^T * X) \neq 0$ y por tanto es invertible.